10.1 聚类分析

2020年7月23日 9:03

目录

- Q 型聚类分析
  - 样本的相似性度量
  - 类与类间的相似性度量
  - 聚类图
  - 最短距离法的聚类示例
  - Matlab 聚类分析命令
- R 型聚类分析
  - 变量相似性度量
  - 变量聚类法
  - 聚类示例

分类的例子：

生物学：界门纲目科属种

企业管理：市场细分

聚类分析（群分析）：对多个样本（或指标）进行定量分类的一种多元统计分析方法

根据分类对象的不同可分为：

Q 型聚类分析：对样本进行分类

R 型聚类分析：对指标进行分类

1. Q 型聚类分析

a. 样本的相似性度量

待分类的样本点用 p 个变量描述，则每个样本点可视为 R^p 空间中的一个点，可用“距离”来度量样本点之间的相似程度

距离的定义：

记 Ω 是样本点集，距离 $d(\boldsymbol{x},\boldsymbol{y})$ 是 $\Omega\times\Omega\to\mathbb{R}^+$ 的一个函数，$\forall \boldsymbol{x},\boldsymbol{y},\boldsymbol{z}\in\Omega$ 满足

1) $d(\boldsymbol{x},\boldsymbol{y})\geq 0$
2) $d(\boldsymbol{x},\boldsymbol{y})=0$ 当且仅当 $\boldsymbol{x}=\boldsymbol{y}$（正定性）
3) $d(\boldsymbol{x},\boldsymbol{y})=d(\boldsymbol{y},\boldsymbol{x})$（对称性）
4) $d(\boldsymbol{x},\boldsymbol{y})\leq d(\boldsymbol{x},\boldsymbol{z})+d(\boldsymbol{z},\boldsymbol{y})$（三角不等式）

常用的距离：闵氏（Minkowski）距离 $d_q(\boldsymbol{x},\boldsymbol{y})=\left[\sum_{k=1}^{p}|x_k-y_k|^q\right]^{\frac{1}{q}}$ ，$q>0$

1) $q=1$, 绝对值距离

$$d_1(\boldsymbol{x},\boldsymbol{y})=\sum_{k=1}^{p}|x_k-y_k|$$

2) $q=2$, 欧几里得（Euclid）距离

$$d_2(\boldsymbol{x},\boldsymbol{y})=\left[\sum_{k=1}^{p}|x_k-y_k|^2\right]^{\frac{1}{2}}$$

3) $q\to\infty$, 切比雪夫（Chebyshev）距离

$$d_\infty(\boldsymbol{x},\boldsymbol{y})=\max_{1\leq k\leq p}|x_k-y_k|$$

最常用的是欧几里得距离，主要优点：坐标轴平移旋转后距离不变

闵氏距离的问题：

变量的量纲必须相同

要避免变量的多重相关性（Multicollinearity）

马氏（Mahalanobis）距离

$$d(\boldsymbol{x},\boldsymbol{y})=\sqrt{(\boldsymbol{x}-\boldsymbol{y})^T\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{y})}$$

其中 Σ 为总体的协方差矩阵，常用样本协方差矩阵来估计

优点：不受量纲影响，对一切线性变换不变

b. 类与类间的相似性度量

对两个样本类 G_1,G_2

1) 最短距离法

$$D(G_1,G_2)=\min_{\substack{x_i\in G_1\\ y_j\in G_2}}\{d(\boldsymbol{x}_i,\boldsymbol{y}_j)\}$$

2) 最长距离法

$$D(G_1,G_2)=\max_{\substack{x_i\in G_1\\ y_j\in G_2}}\{d(\boldsymbol{x}_i,\boldsymbol{y}_j)\}$$

3) 重心法

$$D(G_1,G_2)=d(\overline{\boldsymbol{x}},\overline{\boldsymbol{y}})$$

其中 $\overline{\boldsymbol{x}},\overline{\boldsymbol{y}}$ 分别为两个样本类的重心

4) 类平均法

$$D(G_1,G_2)=\frac{1}{n_1n_2}\sum_{x_i\in G_1}\sum_{x_j\in G_2}d(\boldsymbol{x}_i,\boldsymbol{x}_j)$$

n_1, n_2 分别是两样本类中的样本点个数

5) 离差平方和法

$$D_1=\sum_{x_i\in G_1}(\boldsymbol{x}_i-\overline{\boldsymbol{x}}_1)^T(\boldsymbol{x}_i-\overline{\boldsymbol{x}}_1),D_2=\sum_{x_j\in G_2}(\boldsymbol{x}_j-\overline{\boldsymbol{x}}_2)^T(\boldsymbol{x}_j-\overline{\boldsymbol{x}}_2),D_{12}=\sum_{x_k\in G_1\cup G_2}(\boldsymbol{x}_k-\overline{\boldsymbol{x}})^T(\boldsymbol{x}_k-\overline{\boldsymbol{x}})$$

其中 $\overline{\boldsymbol{x}}_1=\frac{1}{n_1}\sum_{x_i\in G_1}\boldsymbol{x}_i$，$\overline{\boldsymbol{x}}_2=\frac{1}{n_2}\sum_{x_j\in G_2}\boldsymbol{x}_j$，$\overline{\boldsymbol{x}}=\frac{1}{n_1+n_2}\sum_{x_k\in G_1\cup G_2}\boldsymbol{x}_k$

则定义

$$D(G_1,G_2)=D_{12}-D_1-D_2$$

c. 聚类图

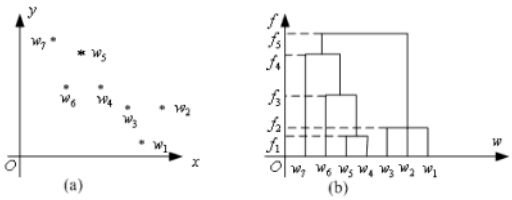

确定距离计算方法后，聚类图可以通过划分不同的平台高度来进行不同的聚类

构建方法：首先计算 n 个样本点两两间距离（样本间的方法），划分为 n 个类，合并最近的两类为新一类，平台高度为这两类之间的距离，计算新类与其余类的距离（类与类的方法），重复以上步骤直到只剩一类

d. 最短距离法的聚类示例

表 1　销售员业绩表

销售员	v_1（销售量）百件	v_2（回收款项）万元
w_1	1	0
w_2	1	1
w_3	3	2
w_4	4	3
w_5	2	5

对这5个销售员的业绩进行聚类，采用绝对值距离，最短距离法

```
clc,clear
a=[1,0;1,1;3,2;4,3;2,5];
y=pdist(a,'cityblock'); %求a的两两行向量间的绝对值距离
yc=squareform(y) %变换成距离方阵
z=linkage(y) %产生等级聚类树
[h,t]=dendrogram(z) %画聚类图
T=cluster(z,'maxclust',3) %把对象划分成3类
for i=1:3
   tm=find(T==i); %求第i类的对象
   tm=reshape(tm,1,length(tm)); %变成行向量
   fprintf('第%d类的有%s\n',i,int2str(tm)); %显示分类结果
end
```

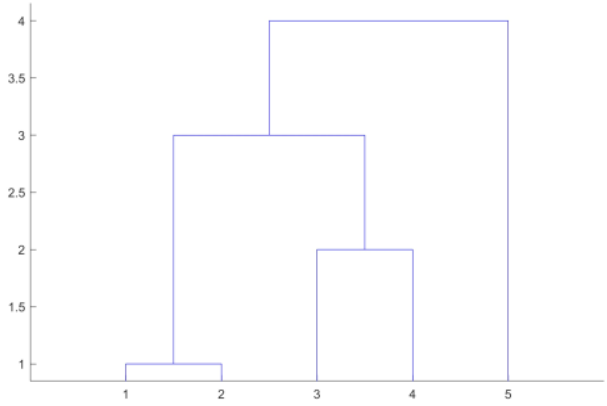

e. Matlab 聚类分析命令

i. Y=pdist(X,'metric')：计算距离

表 10.2　'metric'取值及含义

字符串	含　义	字符串	含　义
'euclidean'	欧氏距离(默认)	'hamming'	海明距离(Hamming 距离)
'seuclidean'	标准欧几里得距离	custom distance function	自定义函数距离
'cityblock'	绝对值距离	'cosine'	1－两个向量夹角的余弦
'minkowski'	闵氏距离(Minkowski 距离)	'correlation'	1－样本的相关系数
'chebychev'	切比雪夫距离(Chebychev 距离)	'spearman'	1－样本的 Spearman 秩相关系数
'mahalanobis'	马氏距离(Mahalanobis 距离)	'jaccard'	1－ Jaccard 系数

注："－"表示减号

Y=pdist(X,'minkowski',p)：闵氏距离，p 为指数

ii. squareform()：将 Y 转换为方阵

iii. Z=linkage(Y)：生成聚类树

表 10.3　'method'取值及含义

字符串	含　义	字符串	含　义
'single'	最短距离(默认)	'median'	赋权重心距离
'average'	无权平均距离	'ward'	离差平方和方法(Ward 方法)
'centroid'	重心距离	'weighted'	赋权平均距离
'complete'	最大距离		

Z的含义：

前两列为类索引，第三列为类距离

新生成的类，索引为原来总类数 +1

iv. T=cluster(Z,'cutoff',c)：从 linkage 输出中创造聚类

表4 cutoff取值及含义

cutoff取值	含　义
0<cutoff<2	cutoff作为不一致系数的阈值。不一致系数对聚类树中对象间的差异进行了量化。如果一个连接的不一致系数大于阈值，则cluster函数将其作为聚类分组的边界。
2<=cutoff	cutoff作为包含在聚类树中的最大分类数

输出 T 存储每个对象所属类的标识，为找到类 i 中的对象，可用 find(T==i)

v. H=dendrogram(Z,P)：生成聚类树状图

2. R 型聚类分析

R 型聚类法目的是分析变量（指标）之间的关系，按照相似性进行分类，找出影响系统的主要因素

a. 变量相似性度量

i. 相关系数

记变量 x_j 的取值 $(x_1j, x_2j, \dots, x_nj)^T \in \mathbb{R}^n$ $(j = 1,2,\dots,m)$ 则相关系数：

$$r_{jk} = \frac{\sum_{i=1}^{n}(x_{ij} - \overline{x_j})(x_{ik} - \overline{x_k})}{\left[\sum_{i=1}^{n}\left(x_{ij} - \overline{x_j}\right)^2 \sum_{i=1}^{n}\left(x_{ik} - \overline{x_k}\right)^2\right]^{\frac{1}{2}}}$$

Matlab操作时首先将数据进行标准化

b = zscore(a)

之后调用函数计算相关系数矩阵

r = corrcoef(b)

ii. 夹角余弦

$$r_{jk} = \frac{\sum_{i=1}^{n} x_{ij}x_{ik}}{\left(\sum_{i=1}^{n} x_{ij}^2 \sum_{i=1}^{n} x_{ik}^2\right)^{\frac{1}{2}}}$$

$|r_{jk}|$ 越接近 1，相似性越强

b. 变量聚类法

类似样本聚类法，可以定义最长距离法、最短距离法

注意距离的定义：

$d_{jk} = 1 - |r_{jk}|$ 或 $d_{jk}^2 = 1 - r_{jk}^2$

c. 聚类示例

在服装标准制定中，对某地成年女子的各部位尺寸进行了统计，通过 14 个部位的测量资料，获得各因素之间的相关系数表

表5 成年女子各部位相关系数

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}	x_{12}	x_{13}	x_{14}
x_1	1													
x_2	0.366	1												
x_3	0.242	0.233	1											
x_4	0.28	0.194	0.59	1										
x_5	0.36	0.324	0.476	0.435	1									
x_6	0.282	0.262	0.483	0.47	0.452	1								
x_7	0.245	0.265	0.54	0.478	0.535	0.663	1							
x_8	0.448	0.345	0.452	0.404	0.431	0.322	0.266	1						
x_9	0.486	0.367	0.365	0.357	0.429	0.283	0.287	0.82	1					
x_{10}	0.648	0.662	0.216	0.032	0.429	0.283	0.263	0.527	0.547	1				
x_{11}	0.689	0.671	0.243	0.313	0.43	0.302	0.294	0.52	0.558	0.957	1			
x_{12}	0.486	0.636	0.174	0.243	0.375	0.296	0.255	0.403	0.417	0.857	0.852	1		
x_{13}	0.133	0.153	0.732	0.477	0.339	0.392	0.446	0.266	0.241	0.054	0.099	0.055	1	
x_{14}	0.376	0.252	0.676	0.581	0.441	0.447	0.44	0.424	0.372	0.363	0.376	0.321	0.627	1

其中 $x_1 \sim x_{14}$ 分别为上体长，手臂长，胸围，颈围，总肩围，总胸宽，后背宽，前腰节高，后腰节高，总体长，身高，下体长，腰围，臀围

用最大系数法进行聚类：

```
clc,clear
a=textread('ch.txt');
d=1-abs(a); %进行数据变换,把相关系数转化为距离
d=tril(d); %提出d矩阵的下三角部分
b=nonzeros(d);%去掉d中的零元素
b=b'; %化成行向量
z=linkage(b,'complete'); %按最长距离法聚类
y=cluster(z,'maxclust',2)  %把变量划分成两类
ind1=find(y==1);ind1=ind1' %显示第一类对应的变量标号
ind2=find(y==2);ind2=ind2' %显示第二类对应的变量标号
h=dendrogram(z); %画聚类图
```
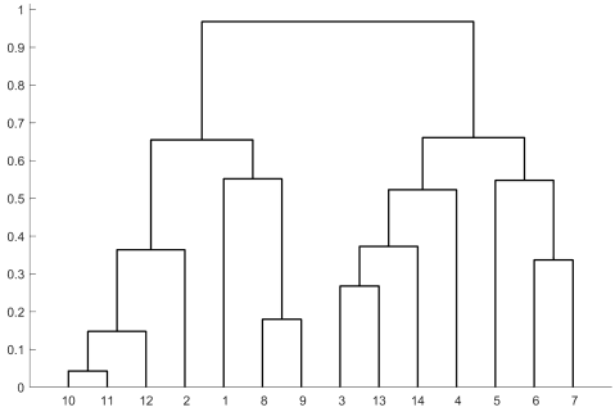
```
set(h,'Color','k','LineWidth',1.3) %把聚类图线的颜色改成黑色，线宽加粗
```